약물 안정화 패턴 기반
중환자실 체류일(LOS) 예측

이재용, 김대건, 송호성, 김지웅

데이터 애널리틱스 프로젝트 3조

목차

Table of Contents

1 프로젝트 주제 및 배경 소개

2 활용 데이터 및 코호트 정의

3 파이프라인

4 피처 엔지니어링

5 모델링 및 결과 해석

6 한계점 및 개선점

배경 소개

중환자실 부족, 일반병동엔 한계‥'준중환자실' 필요성 대두

> 중환자실과 일반병동 사이, 준중환자실 도입으로 의료 공백 해소해야
> 중증 환자 위한 '준중환자실', 독립 운영과 건강보험 수가 적용이 필수

병·의원 › 개원가

심각해진 중환자실 병상 부족 "입퇴실 기준 재논의 시급"

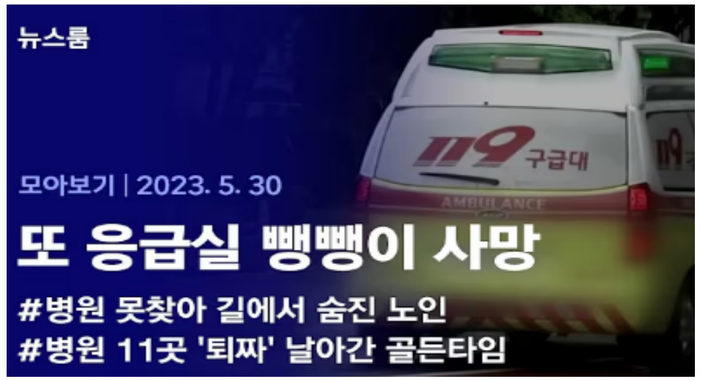

병실, 인력 등 제한된 자원을 적절히 분배할 수 있도록
환자의 체류일(LOS)을 추정하는 것이 필요하다 !

약물 안정화 패턴 기반 중환자실 체류일 예측

정의

투여 약물 패턴 분석 및
생체신호 안정화 지표를 결합
↓
약물 + 생체신호 조합으로
ICU 체류일을 미리 예측하는 모델

중요성

기존의 연구들은 나이, vital 등
환자의 기본적 상태 분석에 의존
↓
투약패턴 + 생리 변화 추세를 활용해
환자 상태와 의사 행동을 동시 반영

목표

다양한 딥러닝 모델 활용 &
SHAP 기반 피처 중요도 분석
↓
의료진이 환자별 체류 예측일과
주요 영향 요인을 직관적으로 파악

약물 안정화 패턴을 반영한 LOS 예측 모델을 통해 해석력 및 임상 활용 가능성 제고

활용 데이터 및 코호트 정의

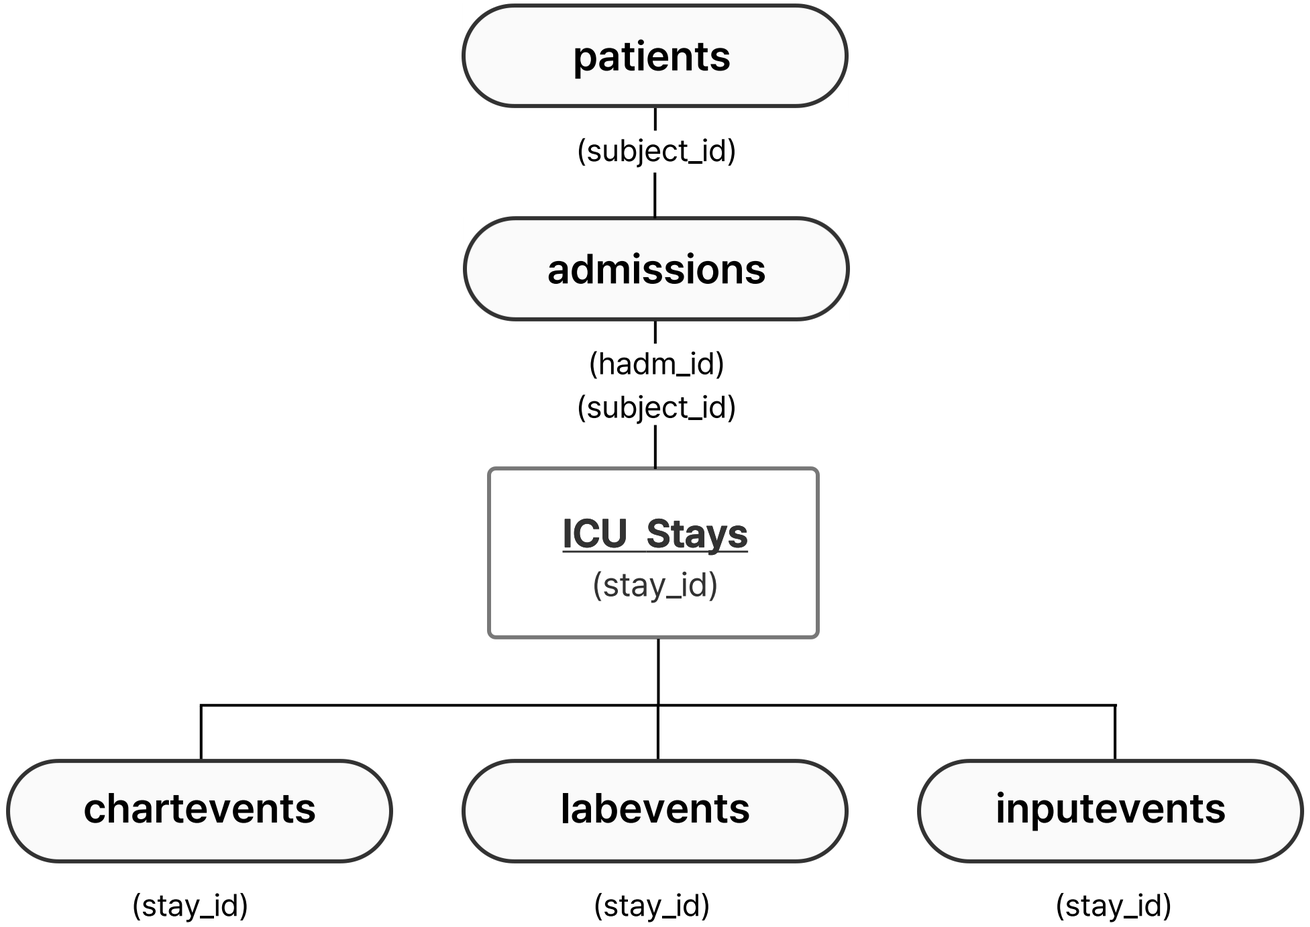

1. 포함/제외 기준

- 단기 퇴원 환자 & 장기 입원 환자 제외
- 성인 환자만 포함
- 사망 환자 제외
- 선택적 입원 환자 제외
- 2010년대 이후 데이터만 활용
- 첫 ICU 입실만 사용 (중복 제거)
- 약물 투여 기록이 있는 환자만 포함
- 관측 구간: 0h - 48h

2. 최종 Base Cohort

Shape: (16349, 30)

파이프라인

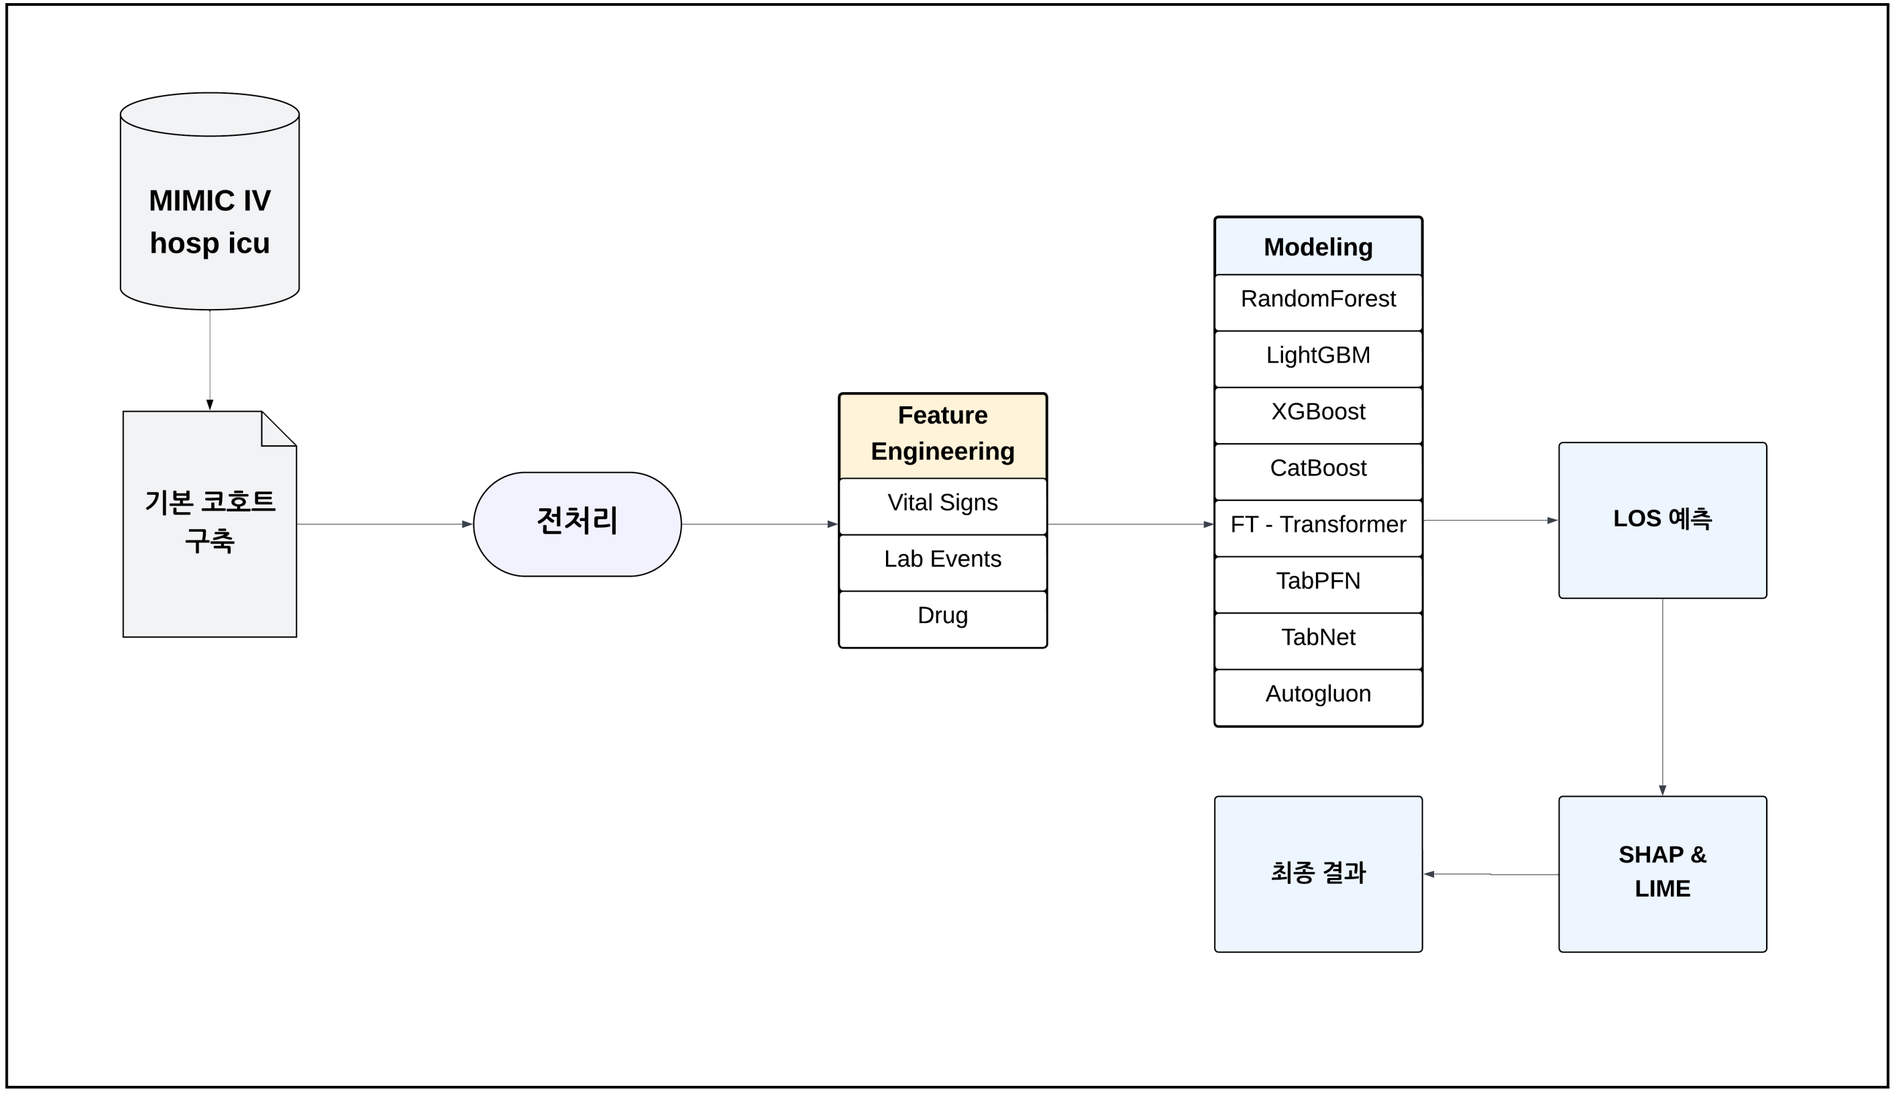
MIMIC IV
hosp icu
기본 코호트
구축
전처리
Feature
Engineering
Vital Signs
Lab Events
Drug
Modeling
RandomForest
LightGBM
XGBoost
CatBoost
FT - Transformer
TabPFN
TabNet
Autogluon
LOS 예측
SHAP &
LIME
최종 결과

피처 엔지니어링

1 Vital Signs

- 분석 Vital 항목
  - HR, MAP, RR, SpO2, Temp, GCS_Verbal, GCS_motor, GCS_Eye, RASS, Pain
- 결측 및 이상치 처리
  - 각 Vital 항목에 대한 이상치 처리 (논문 참조 및 임상학적 근거)
  - 결측률이 높은 MAP, RASS 제외
  - 측정 값에 대한 변동 패턴이 불안정한 Pain 항목 제외

- 시간축 정보 손실 분석
  - MIMIC 데이터는 측정 간격이 불규칙적
    → 시간축 정보 손실 여부 확인을 위해,
    1h - 12h Bin별 존재율 분석 수행

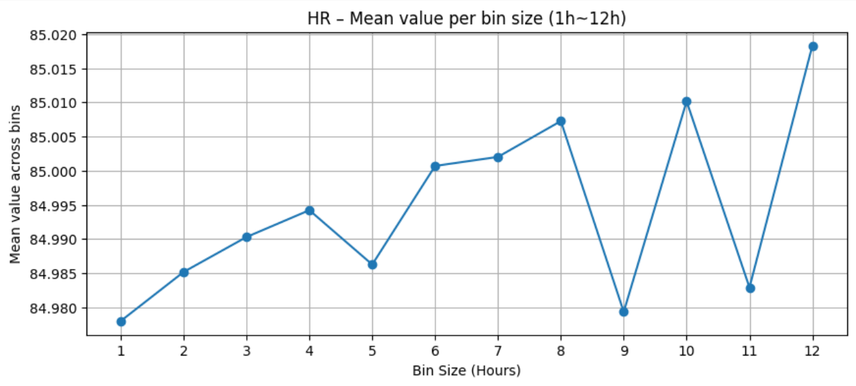

  - Vital 측정 패턴이 Bin 크기에 따라 유의미하게 달라지지 않음
    → 48시간 윈도우 단일 요약 피처 생성

- 최종 Vital 변수
  - HR, RR, Spo2, Temp (생체 신호)
    → 48시간 기준 Mean, Min, Max, Std
  - GCS_Verbal, Motor, Eye (의식 수준 지표)
    → 48시간 기준 Mean, Min, Max
  - 위 항목들에 대해 48시간 내에 한 번도 측정되지 않은 환자 제거
  - Vital Feature Shape: (17583, 25)

피처 엔지니어링

❷ Lab Events

- Lab 변수 항목
  - Lactate, Bicarbonate, pH, AnionGap, Creatinine, Urea Nitrogen(BUN), White Blood Cells, Platelet Count, Glucose, Potassium, Sodium, Bilirubin, Albumin
- 결측 및 이상치 처리
  - lab 항목에 대한 이상치 처리
  - 분포 기반(1%~99%) Clipping
  - 결측률이 높은 Albumin/Bilirubin 제거 제외

- 시간축 정보 손실 분석
  - lab 변수는 시간 별 측정 간격이 길어 24h로 (bin1, bin2)로 나누어 분석

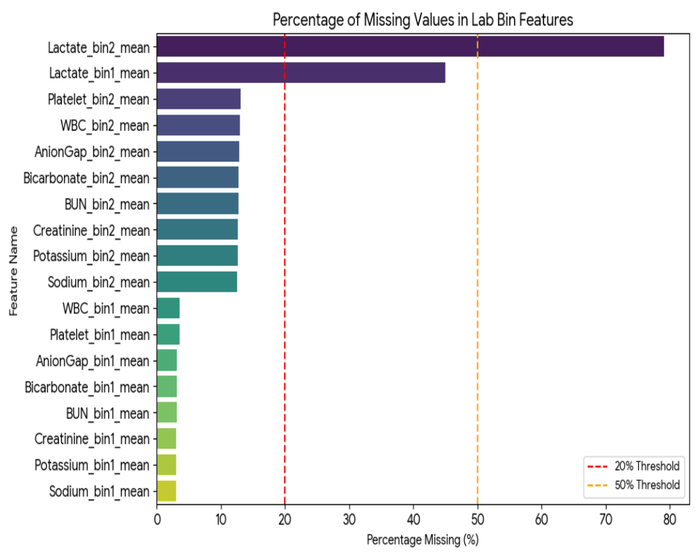

  - Lactate(젖산)에서 높은 결측률을 보임.
  - 대부분의 항목이 낮은 결측률.
  - 모델링 결과에서 중요도가 낮으면 Lactate제거, 혹은 Median imputation 진행.

- 최종 Lab 변수

1. Creatinine, BUN(신장 기능)
2. WBC(감염 및 염증)
3. Platelet Count, Glucose(혈액 기능, 혈당)
4. Lactate, AnionGap, Bicarbonate, pH (쇼크 및 산-염기 균형)
5. Potassium, Sodium(전해질)

  - Vital과 동일하게 48시간 기준 요약 피처 생성
    → Mean, Min, Max, Std로 집계

피처 엔지니어링

❸ Drug

- 그룹 분류:
  - Group 1: 약물 안정성
  - Group 2: 약물 용량& 노출도
  - Group 3: 약물 복잡도
  - Group 4: 약물 중증도& 위험도
- CV(변동계수): 표준편차 / 평균
  - 단위에 구애받지 않음
  - 약물 투여 안정성의 지표
- 약물 표준화: mg/h로 통일
  - 대부분의 약물 전환 가능
  - duration 단위로 계산 가능

그룹	Feature	정의
Group1	overall_rate_cv	약물 투여 변동계수
Group2	analgosedation_intensity	진정제 누적 용량/시간
	total_sedation_exposure	이뇨제 누적 용량
	insulin_requirement	인슐린 누적 용량
	vasoactive_load	혈관제 사용여부 x 시간
Group3	drug_diversity_index	고유 약물 개수 / (최대 동시투여 + 1)
	drug_class_ratio	약물 분류 비율
Group4	critical_medication_score	중증 약물 점수
	medication_escalation	약물 약화 지표
	concurrent_intensity	최대 동시 투여 약물

피처 엔지니어링

❸ Drug(약물 안정화 지수)

- 약물 안정화 지수(Stabilization Index)
  - Stabilization Index
    = α·dose_stability+β·VitalStability

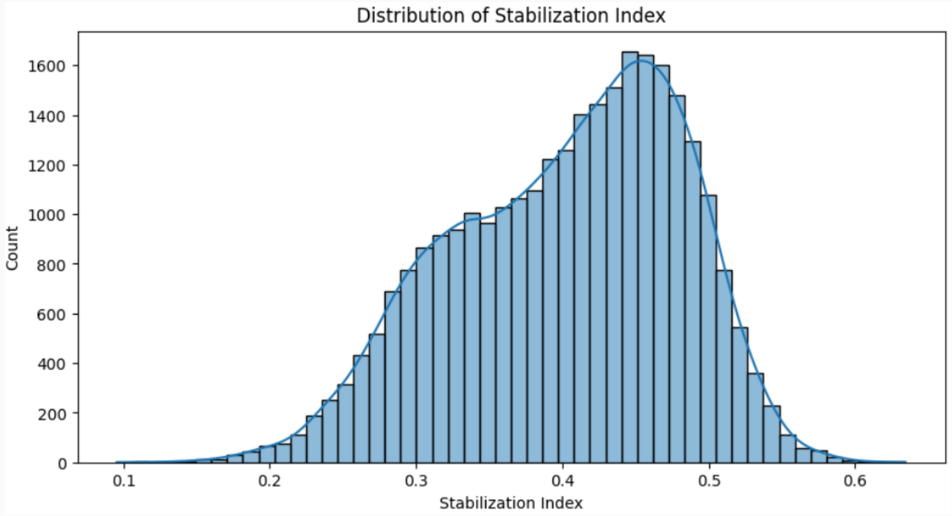

⇑

α + β

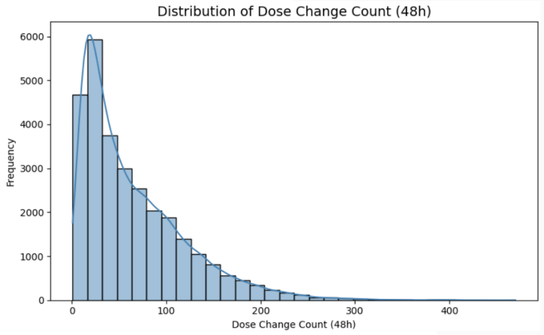

→

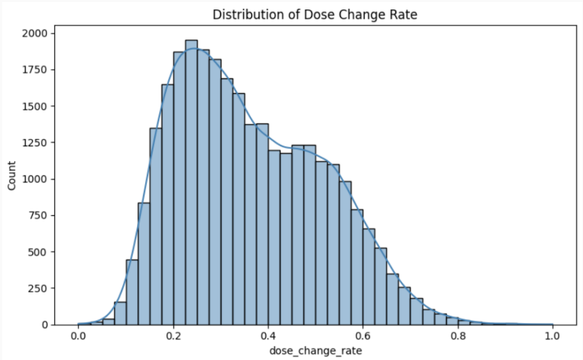

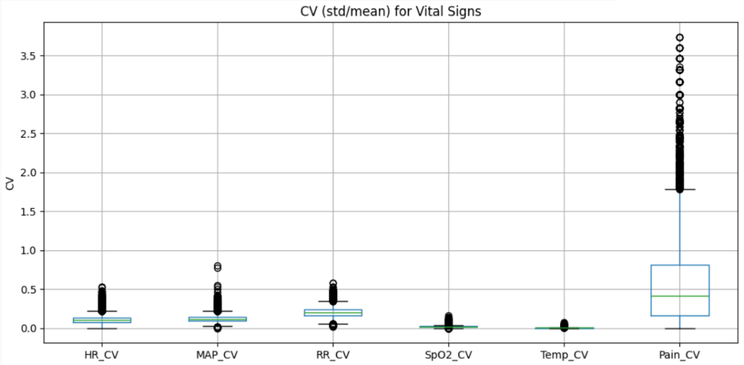

- dose_stability : 48시간 동안 투여 약물 변화율 [0,1]
  - minmaxscaler + quantiletransform

- VitalStability : pain을 제외한 vital sign의 변동계수 (평균/표준편차) [0,1]

피처 엔지니어링

❹ 최종 피처 선택 과정

- 전처리

  (vital+lab / drug 테이블 각각 진행)

- 변수간 상관계수 0.7 이상 제거
- vif 지수 7 이상 제거
- LightGBM 을 기반으로 측정
- train/test 8 : 2
- seed를 바꿔가며 10번 수행 후 평균값 사용

- vital + lab ablation study

- mean만 사용

  MSE : 2.047

- mean + min/max/std 사용

  MSE : 2.015(-0.032)

피처 엔지니어링

❹ 최종 피처 선택 과정

- drug ablation study

  기존 vital+lab 테이블에서 전진선택법으로 drug feature set 탐색

  - Baseline

    MSE : 2.0157

  - Baseline + stability feature

    MSE : 1.9975(-0.0182)

step	add feature	before	after	improvement
1	medication_escalation	1.9975	1.9451	-0.0524
2	vascoactive_load	1.9451	1.9358	-0.0093
3	total_sedation_exposure	1.9358	1.9343	-0.0015
4	concurrent_intensity	1.9343	1.9303	-0.0040
5	drug_class_ratio	1.9303	1.9291	-0.0011
6	drug_diversity_index	1.9291	**1.9256**	-0.0035

total : -0.0901 감소 !

모델링

1 모델 선정 과정

- 후보 모델
  - Tree-based Models:
    Random Forest, LightGBM, XGBoost, CatBoost
  - Deep Learning Models:
    TabNet, FT-Transformer, TabPFN
  - Other(stacking) : Autogluon

- 평가지표
  - 회귀 : MAE, RMSE
  - 분류 : ACC, F1, AUC

Models	Base MAE	Base RMSE	Tuned MAE	TUNED RMSE	Setup
Random Forest	1.9844	3.1335	1.9744	3.1262	5-fold / Optuna / StandardScaler
LightGBM	1.9399	3.0957	1.9347	3.0839	5-fold / Optuna / StandardScaler
XGBoost	1.9668	3.1056	1.9331	3.0935	6-fold / Optuna / MinMaxScaler
CatBoost	1.9732	3.1275	1.9373	3.1161	5-fold / Optuna/ StandardScaler
TabNet	2.1100	3.2817	1.9888	3.2737	5-fold / Optuna / StandardScaler
FT-Transformer	1.870	3.0512	1.855	3.0408	5-fold / Optuna StandardScaler
TabPFN	1.8750	3.052	1.855	3.007	5-fold / Optuna StandardScaler
autogluon	-	-	1.5644	2.5657	-

모델링

❷ Autogluon

- data split
  - 8-fold 학습
- FeatureGenerator(인코딩 및 스케일링)
  - gender 등 2개 값만 있는 컬럼 → boolean 변환
  - 범주형 → category type (CatBoost 방식 사용)
  - 인공신경망 모델의 경우 자체적 normalize
- 학습
  - 총 3 단계로 stacking
  - 1단계 : LightGBM계열, CatBoost 계열, XGBoost 계열 등 여러 모델들의 OOF 예측값 추출 (→2단계에서의 feature값으로 사용)
  - 2단계 : L2 모델들이 1단계에서 뽑은 피쳐를 보고 학습
  - 3단계 : 2단계 모델들의 Weighted Ensemble

- 모델별 가중치
  - NeuralNetTorch_r79_BAG_L2 : 0.208
  - CatBoost_r137_BAG_L2 : 0.208
  - NeuralNetTorch_r79_BAG_L1 : 0.125
  - CatBoost_BAG_L2 : 0.125
  - CatBoost_r177_BAG_L2 : 0.125
  - NeuralNetTorch_r22_BAG_L2 : 0.083
  - XGBoost_r89_BAG_L1 : 0.042
  - NeuralNetTorch_r30_BAG_L1 : 0.042
  - CatBoost_r13_BAG_L2 : 0.042
- 성능
  - MAE : 1.5644
  - RMSE : 2.5657

결과 해석

❶ feature importance / SHAP / LIME

- LIME

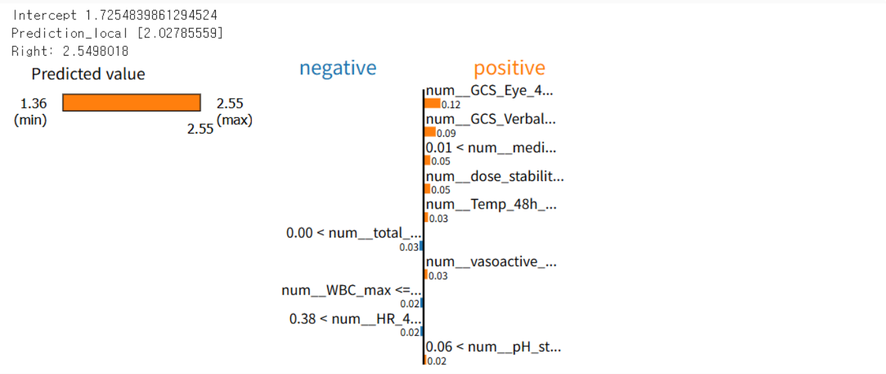

Feature	Value
num__GCS_Eye_48h_mean	0.50
num__GCS_Verbal_48h_mean	0.00
num__medication_escalation	0.02
num__dose_stability	0.50
num__Temp_48h_mean	0.55
num__total_sedation_exposure	0.01
num__vasoactive_load	0.54
num__WBC_max	0.20
num__HR_48h_mean	0.41
num__pH_std	0.16

- feature importance

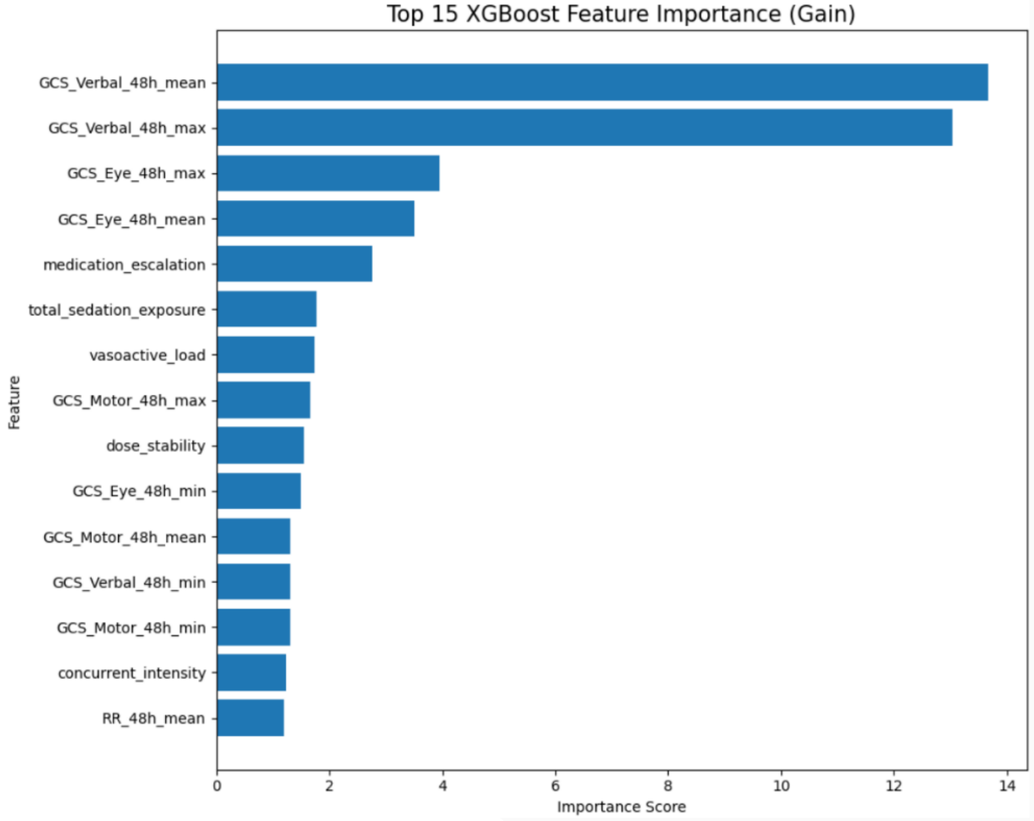

- SHAP

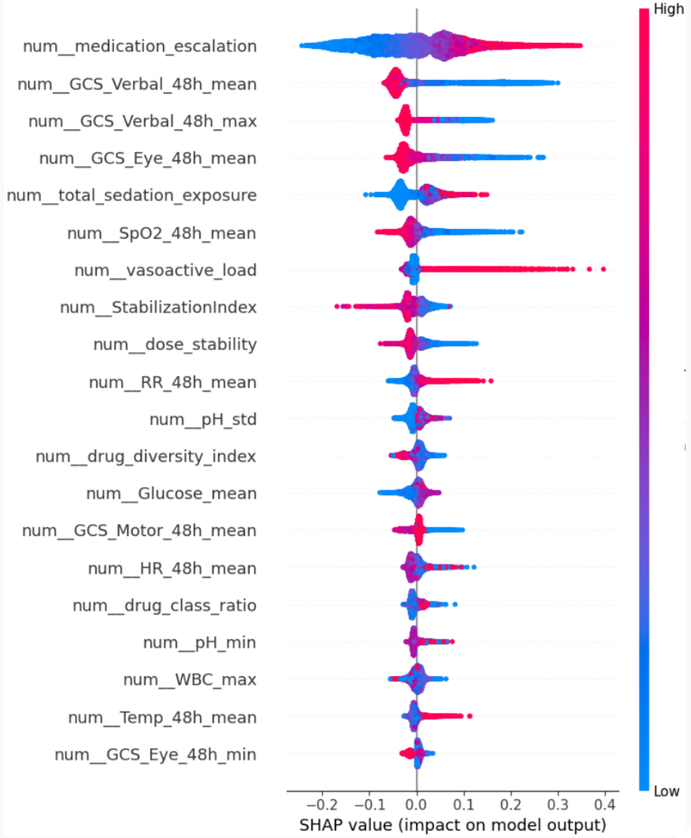

결과 해석

❷ stabilization index

- stabilization index(tuned XGBoost)

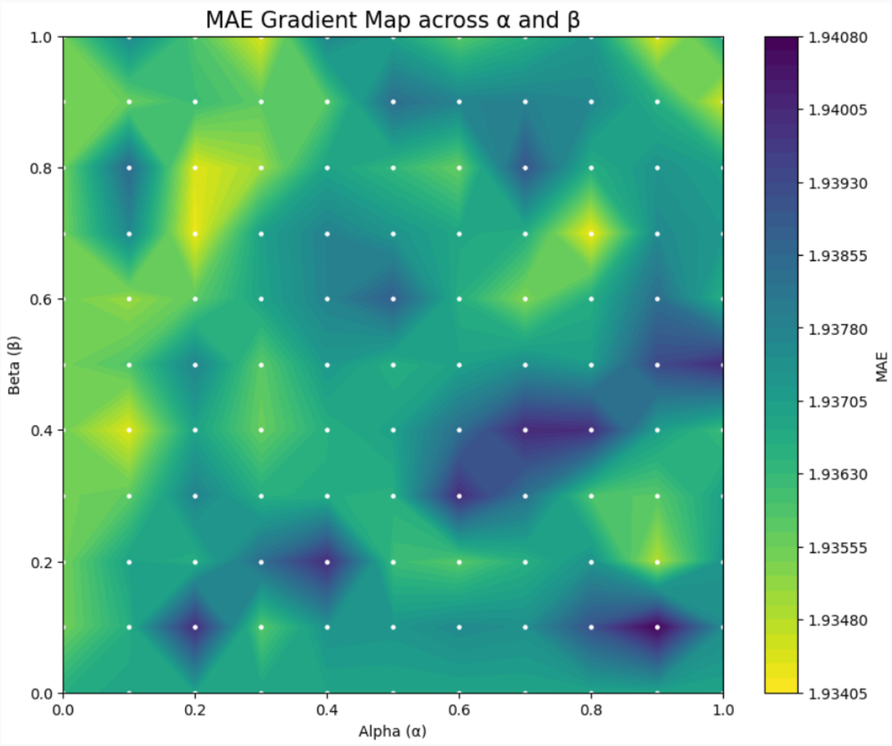

결과 해석

❸ LOS 구간 별 예측 성능

- XGBoost

LoS	Count	True Mean	Pred Mean	MAE	RMSE
2~3 days	6077	2.441	3.268	0.832	0.955
3~4 days	3299	3.449	3.787	0.574	0.811
5~7 days	2086	5.896	5.053	1.320	1.553
7+ days	3031	11.432	7.675	3.880	4.860

과대 예측

과소 예측

- Autogluon

LoS	Count	True Mean	Pred Mean	MAE	RMSE
2~3 days	6077	2.441	2.946	0.536	0.735
3~4 days	3299	3.449	3.509	0.602	0.873
5~7 days	2086	5.896	4.742	1.700	1.960
7+ days	3031	11.432	6.857	4.760	5.846

- 래퍼런스 논문(2023.08) 성능(1~4일)

Method	RMSE	MAE
Linear regression	1.07 (1.14)	0.74 (0.76)
SVM	1.10 (1.16)	**0.71 (0.73)**
Random forest	**1.07 (1.13)**	0.74 (0.76)
XGBoost	1.17 (1.23)	0.81 (0.83)

Prediction of Intensive Care Unit Length of Stay in the MIMIC-IV dataset — L. Hempel , 2023

- 성능 향상은 단기(2~3일) 구간에서 예측 성능 향상
- 장기(5일 이상)에 대해서는 오히려 예측 성능 하락

결과 해석

4 이진 분류 예측 성능

- 래퍼런스 논문(2023.08) 성능

Method	Accuracy	F1	Balanced Accuracy	MCC	AUC
Logistic regression	0.785	0.435	0.609	0.307	0.735
SVM	0.792	0.438	0.610	0.326	0.740
Random forest	**0.810**	**0.442**	0.655	**0.410**	**0.800**
XGBoost	0.802	0.438	**0.671**	0.401	0.777

Prediction of Intensive Care Unit Length of Stay in the MIMIC-IV dataset — L. Hempel , 2023

- 프로젝트 성능

Method	Accuracy	F1	AUC
XGBoost	0.7750	0.5627	0.7912
autogluon	0.8266	0.6680	0.9224

- Confusion Matrix

	Pred 0	Pred 1
Actual 0	10693	584
Actual 1	2258	2859

한계점 및 개선점

- 결론
  - 예측 모델은 2~4일 체류 환자군에서 가장 유의한 성능
    → 입실 초반 환자 상태의 변동성이 길어질수록 LoS가 증가할 가능성이 큼
  - 약물 변화율 및 안정화 지수가 임상적 의미를 가지고 예측 성능 면에서도 유효하게 작용
    → Vital/Lab 에 의존하는 기존 연구의 한계 극복
  - LIME을 통해 개별 환자에 대한 예측 근거 제공
    → 향후 중환자실에서 약물 치료 계획 수립 시 보조적 근거로 활용 가능

- 한계점
  - 벤치마킹 데이터셋의 부재
  - 약물 분석을 inputevents 중심으로만 수행
  - Vital, lab 변수들의 측정 간격 상이
  - 장기 체류 예측이 어려움

- 개선점
  - 회귀 외에 5일 기준 분류 모델 업그레이드
  - ingredientevents/emar등 다중 약물 데이터 소스를 통합
  - 초기 진단을 활용해 환자군을 분류한 후 군별 모델 구축

감사합니다